

Processamento de Bases de Dados em Lote

Melissa Schiavon Pastene (270324)

```
library(readr)
library(dplyr)
```

Warning: pacote 'dplyr' foi compilado no R versão 4.5.3

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

`filter`, `lag`

Os seguintes objetos são mascarados por 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

1. Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

Para determinarmos o percentual de voos atrasados, precisamos apenas identificar quais voos tiveram um atraso superior a 10 minutos. Uma vez que o que buscamos é a proporção de voos atrasados em relação ao total de voos, não é relevante saber em quanto cada voo atrasou.

`percentual = voos atrasados / total de voos`

2. Crie uma função chamada `getStats` que, para um conjunto de qualquer tamanho de dados provenientes de `flights.csv.zip`, execute as seguintes tarefas (usando apenas verbos do `dplyr`):

- Filtre o conjunto de dados de forma que contenha apenas observações das seguintes Cias. Aéreas: AA, DL, UA e US;

- b. Remova observações que tenham valores faltantes em campos de interesse
- c. Agrupe o conjunto de dados resultante de acordo com: dia, mês e cia. aérea;
- d. Para cada grupo em b., determine as estatísticas suficientes apontadas no item 1. e os retorne como um objeto da classe tibble; e.
- e. A função deve receber apenas dois argumentos:
 - i. input: o conjunto de dados (referente ao lote em questão);
 - ii. pos: argumento de posicionamento de ponteiro dentro da base de dados. Apesar de existir na função, este argumento não será empregado internamente. É importante observar que, sem a definição deste argumento, será impossível fazer a leitura por partes.

```
getStats = function(input, pos){
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(ARRIVAL_DELAY)) %>%
    group_by(DAY, MONTH, AIRLINE) %>%
    summarise(
      total = n(),
      voos_atraso = sum(ARRIVAL_DELAY > 10),
      .groups = "drop"
    )
}
```

3. Utilize alguma função `readr::read_*_chunked` para importar o arquivo `flights.csv.zip`.

- a. Configure o tamanho do lote (chunk) para 100 mil registros;
- b. Configure a função de callback para instanciar DataFrames aplicando a função `getStats` criada acima;
- c. Configure o argumento `col_types` de forma que ele leia, diretamente do arquivo, apenas as colunas de interesse (veja nota de aula para identificar como realizar esta tarefa);

```
my_cols = cols_only(AIRLINE = 'c', DAY = 'i', MONTH = 'i', ARRIVAL_DELAY = 'd')

stats <- read_csv_chunked("flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 1e5, col_types = my_cols)
```

4. Crie uma função chamada `computeStats` que:

a\). Combine as estatísticas suficientes para compor a métrica final de interesse (percentual

b\). Retorne as informações em um `tibble` contendo apenas as seguintes colunas:

`i. Cia`: sigla da companhia aérea;

`ii. Data`: data, no formato AAAA-MM-DD (dica: utilize o comando `as.Date`);

`iii. Perc`: percentual de atraso para aquela cia. aérea e data, apresentado como um número

```
computeStats <- function(input) {  
  input %>%  
    mutate(  
      Perc = voos_atraso/total,  
      Data = as.Date(  
        paste(2015, MONTH, DAY, sep = "-")  
      )  
    ) %>%  
    select(  
      Cia = AIRLINE,  
      Data,  
      Perc  
    )  
}  
  
stats <- computeStats(stats)
```

5. Produza um mapa de calor em formato de calendário para cada Cia. Aérea.

a. Instale e carregue os pacotes ggcal e ggplot2.

```
library(devtools)
```

Warning: pacote 'devtools' foi compilado no R versão 4.5.3

Carregando pacotes exigidos: usethis

Warning: pacote 'usethis' foi compilado no R versão 4.5.3

```
devtools::install_github("jayjacobs/ggcal") #Não entendi ao certo se esse era o jeito correto
```

```
Warning: `install_github()` was deprecated in devtools 2.5.0.  
i Please use pak::pak("user/repo") instead.
```

```
WARNING: Rtools is required to build R packages, but is not currently installed.
```

```
Please download and install Rtools 4.5 from https://cran.r-project.org/bin/windows/Rtools/.
```

```
Using github PAT from envvar GITHUB_PAT. Use `gitcreds::gitcreds_set()` and unset GITHUB_PAT
```

```
Skipping install of 'ggcal' from a github remote, the SHA1 (ab1a85ad) has not changed since 1  
Use `force = TRUE` to force installation
```

- b. Defina uma paleta de cores em modo gradiente. Utilize o comando `scale_fill_gradient`. A cor inicial da paleta deve ser `#4575b4` e a cor final, `#d73027`. A paleta deve ser armazenada no objeto `pal`.
- c. Crie uma função chamada `baseCalendario` que recebe 2 argumentos a seguir: `stats` (tibble com resultados calculados na questão 4) e `cia` (sigla da Cia. Aérea de interesse). A função deverá:
 - i. Criar um subconjunto de `stats` de forma a conter informações de atraso e data apenas da
 - ii. Para o subconjunto acima, montar a base do calendário, utilizando `ggcal(x, y)`. Nesta n
 - iii. Retornar para o usuário a base do calendário criada acima.
- d. Executar a função `baseCalendario` para cada uma das Cias. Aéreas e armazenar os resultados, respectivamente, nas variáveis: `CAA`, `CDL`, `cUA` e `cUS`.

```
library(ggplot2)
```

```
Warning: pacote 'ggplot2' foi compilado no R versão 4.5.3
```

```
library(ggcal)

pal <- scale_fill_gradient(low = '#4575b4', high = '#d73027')


baseCalendario <- function(stats, cia) {
  dados <- stats %>%
    filter(Cia == cia)
  ggcal(dados$Data, dados$Perc
)
}

CAA <- baseCalendario(stats, "AA")
CDL <- baseCalendario(stats, "DL")
CUA <- baseCalendario(stats, "UA")
CUS <- baseCalendario(stats, "US")
```

- e. Para cada uma das Cias. Aéreas, apresente o mapa de calor respectivo utilizando a combinação de camadas do `ggplot2`. Lembre-se de adicionar um título utilizando o comando `ggtitle`. Por exemplo, `cXX + pal + ggtitle("Titulo")`.


```
CAA + pal + ggtitle("Mapa de calor da AA")
```

Mapa de calor da AA




```
cDL + pal + ggtitle("Mapa de calor da DL")
```

Mapa de calor da DL




```
cUA + pal + ggtitle("Mapa de calor da UA")
```

Mapa de calor da UA



```
cUS + pal + ggtitle("Mapa de calor da US")
```

Mapa de calor da US



Hora de compilação do arquivo

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-23 12:43:38 -03"
```