Laboratório 9 - ME315

Melissa Schiavon Pastene (270324)

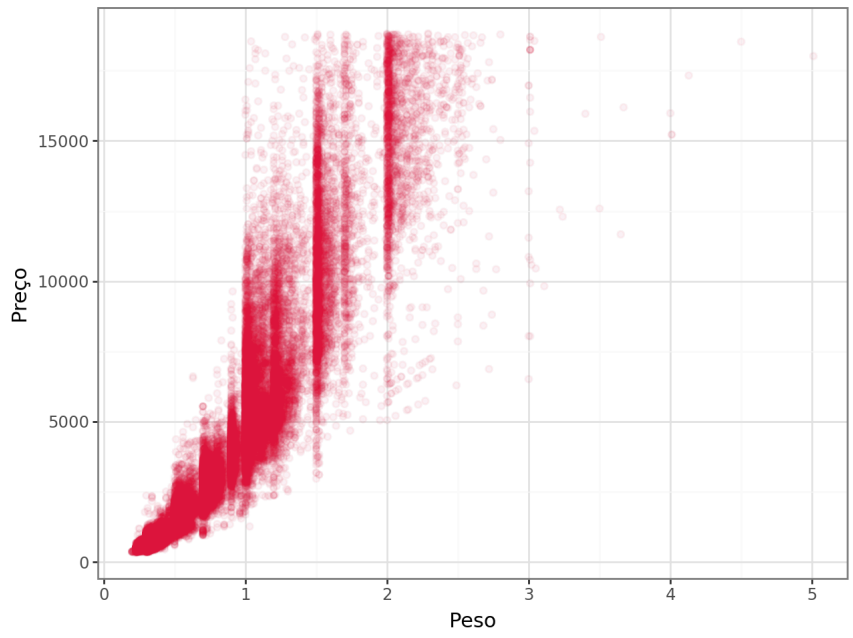
```
!pip install plotnine
import polars as pl
```

1. Importe o conjunto de dados diamonds, cujo arquivo está disponível no website da disciplina.

```
diamonds = pl.read_csv("diamonds.csv.gz")
```

2. Crie uma visualização de dados que descreva a associação existente entre as variáveis peso ***(carat)*** e preço ***(price)***. Que ações você tomou para garantir que você produziu um gráfico de boa qualidade? Escreva um parágrafo comunicando os seus achados.

```
from plotnine import ggplot, aes, geom_point, labs, theme_bw
plot01 = (
    ggplot(diamonds)
    + aes (x = 'carat', y = 'price')
    + geom_point(alpha=0.05, color = 'crimson')
    + labs(x = 'Peso', y = 'Preço')
    + theme_bw()
)
plot01
```



Resposta: Como diamonds possui muitas observações, foi necessário tomar medidas para contornar o problema dos pontos se sobrepontos e se tornando uma única densidade indistingível (overplotting). Apliquei no gráfico de dispersão opacidade de 5% aos pontos para que ficasse possível a visualização das regiões onde a frequência é mais alta. Ademais, é percepitível uma relação positiva entre preço e peso, relação forte até aproximadamente 2,5 quilates, uma vezque após esse ponto parece não ter aumento significativo no preço mesmo com o aumento do peso.

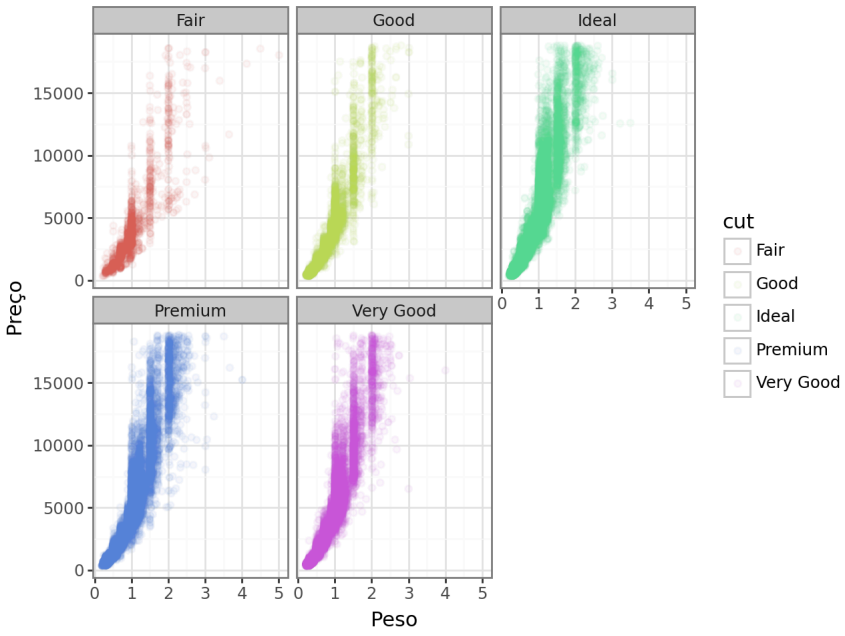
3. A relação identificada na questão anterior é a mesma relação presente nos diferentes cortes de diamantes? Crie uma visualização que demonstre seus achados eficientemente. Descreva sua conclusão em um parágrafo.

Clique duas vezes (ou pressione "Enter") para editar

```
from plotnine import ggplot, aes, geom_point, facet_wrap , labs, theme_bw
plot02 = (
    ggplot(diamonds)
```

```
    + aes (x = 'carat', y = 'price', color = 'cut')
    + geom_point(alpha = 0.05)
    + facet_wrap('cut')
    + labs(x = 'Peso', y = 'Preço')
    + theme_bw()
)

plot02
```



Resposta: A relação se mantém, com a qualidade de corte mais baixa **('Fair')** apareçendo concentrada em dimantes de menor peso e preço, enquanto a qualidade de corte mais alta **('Ideal')** apareçe concentrada seguindo a relação peso e preço, ficando concentrada no intervalo antes dos 2,5 quilates onde a realção preço e peso enfraquece

Fechar

```
### 4. Crie uma visualização que mostre a relação entre preço e diamante, considerando as diferentes combinações de qualidade de clareza do diamante. Quais foram as dificuldades encontradas? A preço e peso é a mesma para diferentes configurações de diamante
```

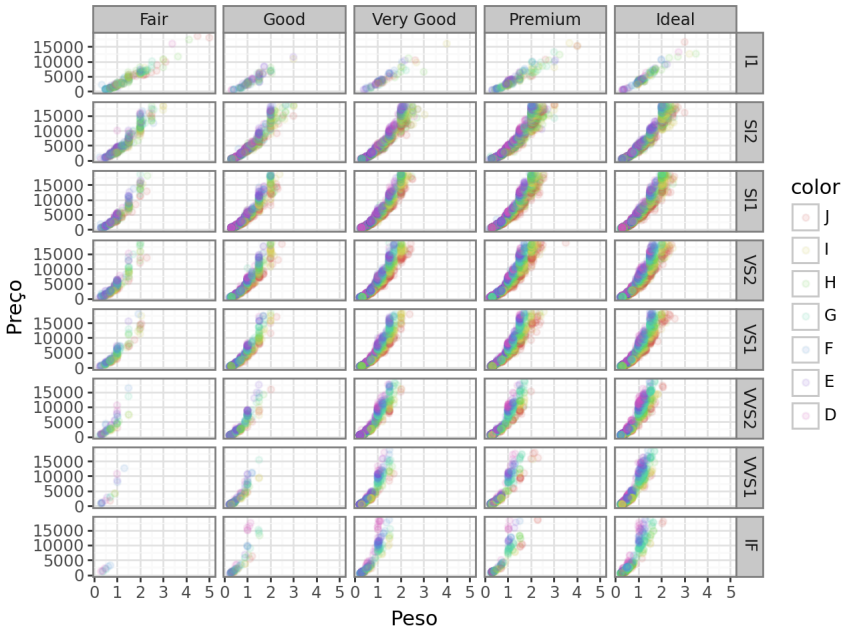
4. Crie uma visualização que mostre a relação entre preço e peso do diamante, considerando as diferentes combinações de qualidade de corte, cor e clareza do diamante. Quais foram as dificuldades encontradas? A relação entre preço e peso é a mesma para diferentes configurações de diamantes?

```
ord_cut = ['Fair', 'Good', 'Very Good', 'Premium', 'Ideal']
ord_color = ['J', 'I', 'H', 'G', 'F', 'E', 'D']
ord_clarity = ['I1', 'SI2', 'SI1', 'VS2', 'VS1', 'VVS2', 'VVS1', 'IF']


ord_diamonds = diamonds.with_columns([
    pl.col('cut').cast(pl.Enum(ord_cut)),
    pl.col('color').cast(pl.Enum(ord_color)),
    pl.col('clarity').cast(pl.Enum(ord_clarity))
])


from plotnine import ggplot, aes, geom_point, facet_grid
plot03 = (
  ggplot(ord_diamonds) + aes(x = 'carat', y = 'price', color = 'color')
  + geom_point(alpha = 0.1)
  + facet_grid("clarity", "cut")
  + labs(x = "Peso", y = "Preço")
  + theme_bw()
)

plot03
```



Resposta: As maiores dificuldades encontradas são trabalhar com múltiplas variáveis. A relação se mantem num parâmetro geral apesar de pontos diferentes como em quando a claridade está em seu nível mais alto